

Modelos y Simulación - FAMAF, UNC

A.D.O.M.

today

En Modelos y Simulación, no podemos predecir el futuro con certeza absoluta, pero podemos modelar la incertidumbre. Para construir simulaciones que representen el mundo real, necesitamos entender el lenguaje del azar: la probabilidad.

Espacio Muestral

Imagina que estás a punto de realizar un experimento que tiene un resultado incierto, como lanzar un dado. El **espacio muestral** (denotado generalmente con la letra griega Ω , Omega) es simplemente el conjunto de todos los resultados posibles de ese experimento.

- **Ejemplo:** Si lanzas un dado estándar de seis caras, tu espacio muestral es $\Omega = \{1, 2, 3, 4, 5, 6\}$.
- **En simulación:** Es el catálogo completo de todo lo que podría pasar en el sistema que estamos modelando.

Eventos

Un evento no es más que un subconjunto del espacio muestral. Es una colección de resultados específicos que nos interesan. Se suelen denotar con letras mayúsculas (A, B, C).

- **Definición:** Si lanzamos nuestro dado, un evento A podría ser “sacar un número par”. En términos de conjuntos, $A = \{2, 4, 6\}$.
- **Eventos mutuamente excluyentes:** Dos eventos son mutuamente excluyentes (o disjuntos) si no pueden ocurrir al mismo tiempo. Es decir, su intersección está vacía ($A \cap B = \emptyset$). Si el evento A es $\{2, 4, 6\}$ y el evento B es $\{1, 3, 5\}$, son mutuamente excluyentes.
- **Mutuamente excluyentes dos a dos:** Se aplica cuando tienes una lista larga de eventos ($A_1, A_2, A_3 \dots$). Lo son si, al tomar cualquier pareja, su intersección es vacía. Ningún evento de la lista se superpone con otro.
- **Eventos independientes:** Dos eventos son independientes si el hecho de que uno ocurra no cambia la probabilidad de que ocurra el otro.

Función de Probabilidad

Es una regla matemática que le asigna a cada evento un número entre 0 y 1 (o entre 0 % y 100 %). Para que esta función sea válida, debe cumplir los **axiomas de Kolmogorov**:

1. $P(A) \geq 0$ para cualquier evento A .
2. $P(\Omega) = 1$ (certeza total de que algo del espacio ocurrirá).
3. Si A y B son mutuamente excluyentes, $P(A \cup B) = P(A) + P(B)$.

Espacio de Probabilidad

Es un modelo matemático completo definido como una terna: $(\Omega, \mathcal{F}, P)$.

- Ω : El espacio muestral.
- $\mathcal{F}$: Conjunto de todos los eventos posibles (Sigma-álgebra).
- P : La función de probabilidad.

Probabilidad Condicional

Es la probabilidad de que ocurra un evento A , sabiendo que ya ocurrió un evento B . Se escribe $P(A|B)$ y reduce nuestro universo original a solo los resultados en B .

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad (1)$$

Fórmula de Bayes

Permite actualizar nuestras creencias cuando obtenemos nueva información:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad (2)$$

Clasificación de Variables Aleatorias

Las variables aleatorias (X, Y) se dividen principalmente por la naturaleza de los valores que pueden tomar.

- **Variables Discretas:** Son aquellas que toman valores contables, con saltos claros entre uno y otro. Piensa en ellas como el equivalente a los enteros (`int`) en C o Python.
 - *Ejemplo:* El número de errores de compilación en un script (0, 1, 2, 3...). No puedes tener 1,5 errores.
- **Variables Continuas:** Pueden tomar cualquier valor dentro de un intervalo infinito. Son como los números de punto flotante (`float` o `double`).
 - *Ejemplo:* El tiempo exacto en milisegundos que tarda un algoritmo en ejecutarse (12,045... ms).
- **Variables Absolutamente Continuas:** Es una subcategoría de las continuas muy exigida en matemáticas formales. Significa que la variable es tan "suave" que no tiene saltos bruscos ni concentraciones de probabilidad en puntos específicos, lo que garantiza que siempre podamos calcular su derivada (su función de densidad, que veremos a continuación).

1. Variable Aleatoria

Es en realidad una **función** que toma cada resultado del espacio muestral (Ω) y le asigna un número real (R). Se denota con letras mayúsculas como X o Y .

Ejemplo: Lanzar dos monedas. $\Omega = \{CC, CX, XC, XX\}$. Si X es el "número de caras":

- Si sale $CCX = 2$.
- Si sale CX o $XCX = 1$.
- Si sale $XXX = 0$.

Una variable aleatoria es una función:

$$X : \Omega \rightarrow R$$

Clasificación de Variables Aleatorias

- **Discretas:** Valores contables
- **Continuas:** Valores en intervalos
- **Absolutamente continuas:** Admiten densidad derivable

Funciones de Distribución (Caso 1D)

Distribución Acumulada (CDF)

$$F(x) = P(X \leq x)$$

Funciones que Describen a una Variable (El caso 1D)

Para modelar cómo se comporta una variable, usamos funciones matemáticas específicas.

- **Distribución Acumulada (CDF):** Es la función "maestra". Aplica tanto para variables discretas como continuas. Nos dice la probabilidad de que nuestra variable X tome un valor menor o igual a un número específico x .

$$F(x) = P(X \leq x)$$

Siempre empieza en 0 y crece hasta llegar a 1.

- **Función de Densidad (PDF):** Solo aplica a variables continuas (y absolutamente continuas). Es la derivada de la distribución acumulada. No nos da probabilidades directas, sino la "densidad" en un punto. Para obtener una probabilidad real, debes calcular el área bajo la curva (integrar) en un intervalo.

$$f(x) = \frac{d}{dx} F(x)$$

Trabajando con Múltiples Variables (El caso 2D o más)

En los modelos reales, las cosas no ocurren aisladas. Múltiples variables interactúan al mismo tiempo.

- **Distribución Acumulada Conjunta:** Es la probabilidad de que dos variables cumplan una condición límite al mismo tiempo.

$$F(x, y) = P(X \leq x, Y \leq y)$$

- **Función de Masa Conjunta:** Para variables discretas. Es la probabilidad exacta de que X valga x e Y valga y simultáneamente. Piensa en esto como buscar un valor específico en una matriz o arreglo bidimensional.

$$p(x, y) = P(X = x, Y = y)$$

- **Función de Densidad Conjunta:** Para variables continuas. Es una superficie en 3D. El volumen bajo esa superficie en una región específica nos da la probabilidad conjunta. Se denota como $f(x, y)$.
- **Distribuciones Marginales:** Supongamos que tienes la información conjunta de X e Y , pero de repente solo te importa X y quieres ignorar Y . Para obtener la distribución "marginal" de X , simplemente sumas (si es discreta) o integras (si es continua) todos los valores posibles de Y , eliminándola de la ecuación para volver al caso 1D.

Condicionalidad Matemática

¿Qué pasa con una variable cuando ya observamos la otra?

- **Probabilidad de Masa Condicional (Discretas):** Es la probabilidad de $X = x$ sabiendo que $Y = y$ ya ocurrió. Se calcula dividiendo la conjunta por la marginal de la variable que ya conocemos.

$$p_{X|Y}(x|y) = \frac{p(x, y)}{p_Y(y)}$$

- **Función de Densidad Condicional (Continuas):** Sigue exactamente la misma lógica, pero usando densidades. Es como hacer un "corte" transversal en nuestra superficie 3D de densidad conjunta.

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$$

Variables Aleatorias Multidimensionales

Distribución Conjunta

$$F(x, y) = P(X \leq x, Y \leq y)$$

Masa / Densidad Conjunta

$$p(x, y) = P(X = x, Y = y) \quad f(x, y)$$

Distribuciones Marginales

$$p_X(x) = \sum_y p(x, y)$$

$$f_X(x) = \int f(x, y) dy$$

Distribuciones Condicionales

$$p_{X|Y}(x|y) = \frac{p(x, y)}{p_Y(y)}$$

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$$

Convolución

La convolución responde a una pregunta clave en simulación: si tengo dos variables aleatorias independientes X e Y , y defino una nueva variable $Z = X + Y$, ¿cuál es la distribución de Z ?

- **Para variables discretas:** Sumamos las probabilidades de todas las combinaciones posibles que sumen z .

$$P(Z = z) = \sum_k P(X = k)P(Y = z - k)$$

- **Para variables continuas:** Hacemos lo mismo, pero con una integral infinita sobre las densidades.

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x)f_Y(z - x)dx$$

Caso Discreto

$$P(Z = z) = \sum_k P(X = k) P(Y = z - k)$$

Caso Continuo

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z - x) dx$$

Medidas de Dispersión y Relación (Momentos)

No siempre necesitamos toda la función de probabilidad; a veces solo necesitamos un resumen numérico del comportamiento de la variable.

- **Varianza:** Mide qué tan dispersos están los valores de una variable respecto a su promedio (su valor esperado). Una varianza alta significa mucha incertidumbre matemática.

$$Var(X) = E[(X - E[X])^2]$$

- **Desviación Estándar:** Es simplemente la raíz cuadrada de la varianza. Se usa porque devuelve el valor a las unidades originales de la variable, haciéndola más intuitiva.

$$\sigma_X = \sqrt{Var(X)}$$

- **Covarianza:** Mide cómo varían dos variables de forma conjunta. Si una sube cuando la otra sube, la covarianza es positiva. Si son completamente independientes, su covarianza es 0.

$$Cov(X, Y) = E[(X - E[X])(Y - E[Y])]$$

Gráfico de Relaciones: Mapa Conceptual

VARIABLES ALEATORIAS (VA)

SEGÚN SU TIPO

- Discretas (Valores contables)
- Continuas (Valores en intervalos)
 - Absolutamente continuas (Derivables sin saltos)

FUNCIONES DESCRIPTIVAS (1 Variable)

- Distribución Acumulada (CDF) --> $P(X \leq x)$ [Aplica a todas]
- Función de Densidad (PDF) --> Derivada de la CDF [Solo continuas]

RELACIONES ENTRE MÚLTIPLES VARIABLES (2 o más)

- Conjuntas (Interacción simultánea)
 - Acumulada Conjunta --> $P(X \leq x, Y \leq y)$
 - Masa Conjunta (Discretas) --> $P(X=x, Y=y)$
 - Densidad Conjunta (Continuas) --> Superficie de probabilidad
- Marginales (Aislar una variable)
 - Se obtiene sumando/integrando la variable no deseada de la Conjunta
- Condicionales (Información previa)
 - Se obtiene dividiendo la Conjunta entre la Marginal de la condición

OPERACIONES ENTRE VARIABLES ($Z = X + Y$)

- Convolución --> Combina distribuciones de variables independientes

RESÚMENES ESTADÍSTICOS (Momentos)

- De una variable:
 - Varianza --> Dispersión al cuadrado
 - Desviación Estándar --> Dispersión en unidades originales
- De dos variables:
 - Covarianza --> Dirección de la relación lineal entre X e Y

Densidad de Probabilidad (PDF)

$$f(x) = \frac{d}{dx} F(x)$$

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

Catálogo de Modelos

En la práctica, no construimos modelos desde cero: utilizamos **familias de distribuciones**. Estas actúan como plantillas matemáticas que describen comportamientos típicos del mundo real.

El Catálogo de Modelos (Distribuciones y el Teorema Central del Límite)

Hasta ahora hemos hablado de la probabilidad en términos abstractos. Sin embargo, en la práctica de la simulación y el modelado, no inventamos las reglas desde cero cada vez. La naturaleza y los sistemas informáticos tienden a comportarse siguiendo patrones muy específicos.

A estos patrones los llamamos "familias de distribuciones". Piensa en ellas como plantillas predefinidas. Si logramos identificar a qué plantilla se parece nuestro problema (ya sea modelar la mutación en una secuencia genética o el tráfico de paquetes en una red), la matemática nos dará casi todas las respuestas.

Dividiremos nuestro catálogo en las dos categorías que definimos antes: discretas y continuas.

Distribuciones Discretas (Para contar eventos)

Estas distribuciones se utilizan cuando nuestros resultados son números enteros o categorías. Nos sirven para contar cosas.

- **Uniforme Discreta:** Es el modelo del azar perfecto y equitativo. Todos los resultados posibles en un conjunto finito tienen exactamente la misma probabilidad de ocurrir.
 - *Intuición:* Lanzar un dado justo o seleccionar un índice aleatorio de un arreglo en memoria. Si hay n elementos, la probabilidad de cada uno es $1/n$.
- **Bernoulli:** Es el bloque constructor más básico. Modela un experimento que solo tiene dos resultados posibles: "Éxito" (con probabilidad p) o "Fracaso" (con probabilidad $1 - p$).
 - *Intuición:* Es un interruptor booleano. Modela si un bit se transmite con error (1) o sin error (0), o si una célula de prueba responde a un estímulo o no.
- **Binomial:** Si tomas el experimento de Bernoulli y lo repites n veces de forma independiente, la distribución Binomial cuenta el número total de "Éxitos".
 - *Intuición:* Si tienes una placa con 100 bacterias independientes y cada una tiene una probabilidad p de sobrevivir a un antibiótico, este modelo te dice cuál es la probabilidad de que sobrevivan exactamente k bacterias. Se denota $X \sim \text{Bin}(n, p)$.
- **Poisson:** Modela la cantidad de veces que ocurre un evento en un intervalo de tiempo o espacio continuo, asumiendo que los eventos ocurren a una tasa promedio constante (λ) y son independientes.
 - *Intuición:* Ideal para contar eventos raros. Por ejemplo, el número de mutaciones puntuales en una cadena de ADN de longitud fija, o el número de peticiones por segundo que llegan a un servidor. Se denota $X \sim \text{Poisson}(\lambda)$.
- **Geométrica:** En lugar de contar éxitos en un número fijo de intentos, aquí contamos la cantidad de intentos necesarios para conseguir el primer éxito.
 - *Intuición:* Modela la búsqueda. ¿Cuántos nucleótidos debo leer en una secuencia hasta encontrar un codón de inicio específico? ¿Cuántas veces debe ejecutarse un bucle hasta que falle por primera vez?
- **Binomial Negativa (o Pascal):** Es la hermana mayor de la Geométrica. Modela la cantidad de intentos necesarios para conseguir el r -ésimo éxito, no solo el primero.
 - *Intuición:* Si necesitas aislar 5 cultivos celulares viables de una muestra difícil, esta distribución modela cuántas extracciones en total tendrás que realizar hasta lograr tu objetivo.
- **Hipergeométrica:** Es similar a la Binomial (contar éxitos), pero con una diferencia crucial: no hay reemplazo. Por lo tanto, los intentos ya no son independientes, porque el universo cambia tras cada extracción.
 - *Intuición:* Tienes un ecosistema con un número conocido de especies, algunas marcadas y otras no. Si capturas una muestra aleatoria para un estudio poblacional, la hipergeométrica te dice la probabilidad de cuántas de esas especies estarán marcadas.

Distribuciones Continuas (Para medir magnitudes)

Estas distribuciones se usan cuando medimos cosas como tiempo, distancia, peso o energía, donde los valores pueden ser tan precisos como queramos (infinitos decimales).

- **Uniforme Continua:** Todos los valores dentro de un intervalo $[a, b]$ tienen exactamente la misma densidad de probabilidad.
 - *Intuición:* Es la función fundamental de la simulación por computadora. Cuando usas lenguajes como Python o C para generar números aleatorios básicos, el motor te entrega un valor bajo una distribución uniforme entre 0 y 1. A partir de ella, matemáticamente se construyen todas las demás distribuciones.
- **Normal (Gaussiana):** La famosa "campana de Gauss". Es la distribución más importante de la estadística. Se concentra alrededor de una media (μ) y se dispersa simétricamente según su desviación estándar (σ).

- *Intuición:* Modela características biológicas (como la altura o la presión arterial) y errores de medición. Aparece siempre que un fenómeno es el resultado de sumar muchísimos factores pequeños e independientes.
- **Normal Estándar:** Es simplemente una distribución Normal que ha sido normalizada para tener media $\mu = 0$ y varianza $\sigma^2 = 1$.
 - *Intuición:* Es una herramienta de estandarización. Nos permite comparar peras con manzanas, transformando cualquier variable Normal a esta escala estándar mediante los "z-scores". Se denota $Z \sim \mathcal{N}(0, 1)$.
- **Exponencial:** Modela el tiempo de espera entre eventos en un proceso de Poisson. Tiene una propiedad fascinante: "no tiene memoria". Que hayas esperado mucho tiempo no aumenta la probabilidad de que el evento ocurra en el siguiente instante.
 - *Intuición:* Modela el tiempo de decaimiento de una partícula radiactiva, o el tiempo que transcurre hasta que un componente de hardware falla por azar.
- **Lognormal:** Una variable tiene distribución lognormal si su logaritmo natural sigue una distribución normal. Es asimétrica y solo toma valores positivos.
 - *Intuición:* Excelente para modelar procesos que crecen de forma multiplicativa (y no aditiva). Por ejemplo, la proliferación de un tejido biológico, o la distribución de tamaños de archivos en un sistema operativo.
- **Gamma:** Es la versión continua de la Binomial Negativa. Modela el tiempo total de espera hasta que ocurren k eventos en un proceso de Poisson.
 - *Intuición:* Si un proceso informático o biológico necesita completar una serie de sub-fases secuenciales (donde cada fase toma un tiempo exponencial), el tiempo total del proceso sigue una distribución Gamma.
- **Weibull:** Supera una limitación de la distribución exponencial, ya que permite que la tasa de falla cambie con el tiempo.
 - *Intuición:* Es la reina del "Análisis de Supervivencia". Si quieres modelar cuánto tiempo vivirá una célula bajo estrés térmico, o cuándo fallará un motor físico donde las piezas sufren desgaste (la probabilidad de fallar aumenta con la edad), usas Weibull.

El Teorema Central del Límite (TCL)

Si tuviera que elegir un solo concepto como la piedra angular del análisis de datos y la simulación, sería este.

La Definición Formal: Si tomas una muestra lo suficientemente grande (usualmente $n > 30$) de una población con media μ y varianza σ^2 , la distribución de las sumas (o medias muestrales) se aproximará a una distribución Normal, sin importar qué forma tuviera la distribución original de los datos.

La Intuición: Imagina que tienes una variable aleatoria horriblemente distribuida, totalmente caótica y asimétrica. Si extraes muchas muestras de esa variable y promedias los resultados repetidamente, esos promedios mágicamente formarán una campana de Gauss perfecta.

¿Por qué es vital para modelar? Porque explica por qué la curva Normal aparece en todas partes en la naturaleza y la computación. El ruido de fondo de un sensor, las variaciones fenotípicas complejas, o el tiempo de ejecución de un programa masivamente paralelo, no son eventos simples. Son la suma de millones de eventos microscópicos (variables aleatorias independientes). El TCL garantiza que esa macro-suma se comporte como una Normal, permitiéndonos predecir sistemas inmensamente complejos usando matemática relativamente simple.

Distribuciones Discretas vistas desde otro modo: versión resumen

Uniforme Discreta

Teoría: Todos los valores tienen igual probabilidad.

Fórmula:

$$P(X = x_i) = \frac{1}{n}$$

Intuición: Azar perfecto (dado justo).

Ejemplo: Elegir un índice al azar en un arreglo de tamaño n .

Bernoulli

Teoría: Experimento con dos resultados.

Fórmula:

$$P(X = 1) = p, \quad P(X = 0) = 1 - p$$

Intuición: Interruptor ON/OFF.

Ejemplo: Bit con error (1) o correcto (0).

Binomial

Teoría: Número de éxitos en n ensayos independientes.

Fórmula:

$$P(X = k) = np^k(1 - p)^{n-k}$$

Intuición: Contar éxitos repetidos.

Ejemplo: Bacterias que sobreviven a un antibiótico.

Poisson

Teoría: Número de eventos en un intervalo.

Fórmula:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

Intuición: Eventos raros.

Ejemplo: Peticiones por segundo en un servidor.

Geométrica

Teoría: Intentos hasta el primer éxito.

Fórmula:

$$P(X = k) = (1 - p)^{k-1}p$$

Intuición: Búsqueda.

Ejemplo: Intentos hasta encontrar un patrón.

Binomial Negativa

Teoría: Intentos hasta el r -ésimo éxito.

Intuición: Generalización de la geométrica.

Ejemplo: Ensayos necesarios para obtener múltiples éxitos.

Hipergeométrica

Teoría: Muestreo sin reemplazo.

Fórmula:

$$P(X = k) = \frac{KkN - Kn - k}{Nn}$$

Intuición: El universo cambia.

Ejemplo: Especies marcadas en una muestra.

Distribuciones Continuas vistas desde otro modo: versión resumen

Uniforme Continua

Teoría: Densidad constante en $[a, b]$.

Fórmula:

$$f(x) = \frac{1}{b - a}$$

Intuición: Base de generación aleatoria.

Ejemplo: `random()` en programación.

Normal (Gaussiana)

Teoría: Distribución simétrica centrada en μ .

Fórmula:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Intuición: Suma de muchos efectos pequeños.

Ejemplo: Altura humana.

Normal Estándar

Teoría: Caso especial con $\mu = 0$, $\sigma = 1$.

Fórmula:

$$Z = \frac{X - \mu}{\sigma}$$

Intuición: Escala universal.

Ejemplo: Z-scores.

Exponencial

Teoría: Tiempo entre eventos.

Fórmula:

$$f(x) = \lambda e^{-\lambda x}$$

Intuición: Sin memoria.

Ejemplo: Tiempo hasta falla de hardware.

Lognormal

Teoría: Logaritmo normal.

Intuición: Crecimiento multiplicativo.

Ejemplo: Tamaño de archivos.

Gamma

Teoría: Tiempo hasta k eventos.

Intuición: Suma de exponenciales.

Ejemplo: Procesos por etapas.

Weibull

Teoría: Tasa de falla variable.

Intuición: Desgaste.

Ejemplo: Vida útil de componentes.

Teorema Central del Límite visto desde otro punto de vista: versión resumen

Teoría

Si n es grande:

$$\bar{X} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

Intuición

Promedios de variables caóticas $\rightarrow$ distribución normal.

Ejemplo

Ruido en sensores o sistemas complejos.

Importancia

Explica por qué la distribución normal aparece en casi todos los sistemas reales.

Procesos Estocásticos y el Mundo de Poisson

Hasta ahora, hemos analizado variables aleatorias como si fueran "fotos": un instante congelado en el tiempo donde observamos un resultado. Pero en Modelos y Simulación, el mundo real es una película. Los eventos ocurren a lo largo del tiempo.

Para modelar esto, necesitamos dar el salto de las variables aleatorias a los **procesos estocásticos**. Y el rey absoluto de los procesos de conteo en tiempo continuo es el Proceso de Poisson.

A continuación, desglosaremos sus componentes fundamentales.

Proceso de Poisson Homogéneo de Intensidad λ

Un proceso estocástico $N(t)$ es una familia de variables aleatorias indexadas por el tiempo. En el caso del proceso de Poisson, $N(t)$ cuenta la cantidad total de eventos que han ocurrido desde el tiempo 0 hasta el tiempo t .

Se llama "homogéneo" porque los eventos ocurren a una tasa promedio constante a lo largo del tiempo. Esa tasa promedio es la **intensidad** o **tasa de arribos**, denotada con la letra griega λ (lambda).

- **La Intuición:** Imagina que λ es la velocidad de un flujo constante. Si $\lambda = 5$ eventos por minuto, sabes que, en promedio, verás 5 eventos cada 60 segundos. No sabes exactamente en qué milisegundo ocurrirá cada uno, pero conoces el ritmo general.
- **Ejemplo Práctico:** En ciencias de la computación, λ podría representar la tasa a la que llegan peticiones HTTP a un servidor web (ej. 100 peticiones por segundo). En biología computacional, podría ser la tasa constante a la que ocurren mutaciones puntuales en una secuencia genómica a lo largo del tiempo evolutivo.

La Anatomía de los Incrementos

Un incremento.^{es} simplemente el número de eventos que ocurren en un intervalo de tiempo específico. Se expresa como la diferencia $N(t+s) - N(t)$, que representa cuántos eventos sucedieron en un lapso de duración s .

Para que un proceso de conteo sea formalmente un Proceso de Poisson, sus incrementos deben cumplir dos reglas de oro:

- **Incrementos Independientes:** La cantidad de eventos en un intervalo de tiempo no tiene ninguna influencia sobre la cantidad de eventos en otro intervalo que no se superponga.
 - *Intuición y Ejemplo:* Si un servidor web recibió una ráfaga masiva de tráfico entre las 10:00 y las 10:05, eso no cambia en absoluto la probabilidad de recibir mucho o poco tráfico entre las 10:05 y las 10:10. El sistema no tiene "memoria".
- **Incrementos Estacionarios:** La distribución de probabilidad del número de eventos en un intervalo depende únicamente de la *duración* del intervalo, no de cuándo empieza.
 - *Intuición y Ejemplo:* La probabilidad de que ocurran 3 mutaciones celulares en un lapso de 5 años es matemáticamente idéntica si esos 5 años se miden en la primera década de vida del organismo o en la tercera. Solo importa que el lapso dura 5 años.
- **Intensidad del Incremento:** Gracias a estas propiedades, la cantidad de eventos en cualquier intervalo de longitud s sigue una distribución de Poisson con un parámetro ajustado por el tiempo: λs .

$$P(N(t+s) - N(t) = k) = \frac{e^{-\lambda s} (\lambda s)^k}{k!}$$

Proceso de Poisson Homogéneo Traslado

Este concepto surge directamente de la propiedad de incrementos estacionarios. Si tomas un proceso de Poisson y decides reiniciar tu cronómetro en un tiempo arbitrario $t_0 > 0$, el proceso resultante a partir de ese momento es estadísticamente idéntico al original.

- **La Intuición:** No importa en qué momento decidas empezar a observar el sistema; si el proceso es homogéneo, la física matemática del azar no cambia. Si empiezas a simular el tráfico de red al mediodía o a las tres de la tarde, las ecuaciones que rigen el tiempo de espera hasta el próximo paquete son exactamente las mismas.

Distribución del Tiempo entre Arribos

Si el proceso $N(t)$ cuenta *cuántos* eventos ocurren, el tiempo entre arribos mide *cuánto tiempo pasa* de un evento al siguiente. Llamemos T_1 al tiempo hasta el primer evento, T_2 al tiempo entre el primer y segundo evento, y así sucesivamente.

En un Proceso de Poisson Homogéneo, los tiempos entre arribos T_i son variables aleatorias continuas, independientes, y siguen una **distribución Exponencial** con parámetro λ .

- **La Intuición:** La distribución exponencial y la distribución de Poisson son dos caras de la misma moneda. Poisson cuenta el número de eventos en un tiempo fijo; Exponencial mide el tiempo continuo entre eventos individuales.
- **Ejemplo Práctico:** Si las peticiones a una base de datos siguen un proceso de Poisson con $\lambda = 10$ por segundo, el tiempo exacto que transcurre entre que llega la petición A y la petición B sigue una distribución exponencial con media $1/10$ de segundo (100 milisegundos).

Superposición de Procesos

En simulaciones complejas, a menudo tenemos múltiples fuentes de eventos operando en paralelo. La superposición nos dice qué pasa cuando las combinamos.

Si tienes dos procesos de Poisson independientes, uno con tasa λ_1 y otro con tasa λ_2 , y los combinas en un solo flujo, el resultado es un nuevo Proceso de Poisson perfectamente válido con una tasa sumada $\lambda = \lambda_1 + \lambda_2$.

- **La Intuición:** Las corrientes se suman.
- **Ejemplo Práctico:** Tienes dos clústeres de servidores independientes enviando registros (logs) a una misma base de datos central. El clúster A envía logs a una tasa λ_1 , y el clúster B a una tasa λ_2 . Para la base de datos central, el flujo entrante total es un solo proceso de Poisson con tasa $\lambda_1 + \lambda_2$.

Adelgazamiento (Thinning)

El adelgazamiento es la operación inversa a la superposición. Supongamos que tienes un proceso de Poisson original con tasa λ , pero cada vez que ocurre un evento, lo "filtras." lo clasificas de forma independiente. Con una probabilidad p lo aceptas, y con probabilidad $1 - p$ lo rechazas.

El teorema de adelgazamiento demuestra que los eventos aceptados forman un nuevo Proceso de Poisson con tasa λp , y los rechazados forman otro proceso independiente con tasa $\lambda(1 - p)$.

- **La Intuición:** Es como tamizar arena. Filtramos un proceso denso y obtenemos un proceso más "delgado" (thinning), pero que conserva la naturaleza sin memoria de Poisson.
- **Ejemplo Práctico:** Un cortafuegos (firewall) inspecciona paquetes de red que llegan según un proceso de Poisson a tasa λ . Si el cortafuegos detecta y bloquea paquetes maliciosos (que representan el 5 % del tráfico, $p = 0,05$), los paquetes bloqueados forman su propio proceso de Poisson con tasa $\lambda \times 0,05$.

Procesos de Poisson No Homogéneos

Finalmente, rompemos la regla principal para acercarnos aún más a la realidad. En un proceso no homogéneo, la intensidad ya no es una constante λ , sino una función del tiempo: $\lambda(t)$.

Aquí, los incrementos siguen siendo independientes, pero **ya no son estacionarios**. La probabilidad de que ocurran eventos depende absolutamente de qué hora marca el reloj.

- **La Intuición:** El ritmo del flujo varía, acelerándose y desacelerándose según avanza el tiempo.
- **Ejemplo Práctico:** El uso de CPU en un servidor de una universidad no es constante. Sigue una curva $\lambda(t)$ que es muy baja a las 3:00 AM, sube abruptamente a las 9:00 AM cuando inician las clases, y tiene picos cerca de las fechas de exámenes. Para calcular el número esperado de eventos entre el tiempo t_1 y t_2 , ya no multiplicamos, sino que integramos la función de intensidad:

$$E[N(t_2) - N(t_1)] = \int_{t_1}^{t_2} \lambda(t) dt$$

Mapas Conceptuales y Diagramas




Figura 1: Clasificación y relaciones de las Variables Aleatorias.




Figura 2: Distribuciones probabilísticas discretas y continuas.




Figura 3: Esquema fundamental de los Procesos de Poisson.